Visão Computacional na Análise da Postura Humana: Um Estudo de Caso

Brendoon R. R. Aboboreira[1], Pedro H. C. Braga[1]

[1]Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie (MACKENZIE) – São Paulo, SP – Brazil

brendoon.rocha@mackenzista.com.br, pedro.braga@mackenzie.br

Abstract. *In this article, we explore the application of computer vision in the analysis of human posture and range of motion, through technologies embedded in mobile devices, such as smartphones and tablets, in order to help capture more objective data with less risk of bias. The hypothesis presented here considers the development of a mobile app, for iOS, to assist in the physical assessment process, covering from implementation aspects to the analysis of data obtained by using the application, observing characteristics such as: capacity, necessities, limitations and obstacles faced.*

Resumo. *Nesse artigo, nós exploramos a aplicação da visão computacional na análise da postura e amplitude de movimento humanos, através das tecnologias embarcadas em dispositivos móveis, tais como smartphones e tablets, a fim de auxiliar na captura de dados mais objetivos e com menos risco de viés. A hipótese aqui apresentada considera o desenvolvimento de um aplicativo mobile para iOS para auxiliar no processo de avaliação física, contemplando desde aspectos de implementação até a análise dos dados obtidos pelo uso do aplicativo, observando características como: capacidade, necessidades, limitações e obstáculos enfrentados.*

1. Introdução

A medição da postura e da amplitude de movimento (ADM) humanos é uma área de pesquisa essencial nos campos de bioengenharia e reabilitação. É motivado por diferentes objetivos na aplicação clínica, como comparar movimentos normais com movimentos patológicos, planejar e avaliar protocolos de tratamento e o desenho de órteses e próteses (WONG et al. 2007). A postura e a ADM humanos também são fatores importantes de uma avaliação física e, a partir dos dados coletados, é possível identificar desvios posturais como escoliose ou limitações articulares e musculares (MAGEE e MANSKE, 2020).

Um dos métodos mais amplamente usados para analisar os desvios da postura humana é a inspeção visual e palpação (TUNNELL, 1996). Esse método é altamente subjetivo, dependente do avaliador e possui baixa precisão e escala (WATSON e DONNCHA, 2000; RADAŠ e TROŠT BOBIC, 2011). Como consequência, no campo da ergonomia por exemplo, os resultados imprecisos das avaliações observacionais podem levar a intervenções ineficazes para reduzir fatores de risco do trabalho para distúrbios musculoesqueléticos relacionados ao trabalho (CDC, 2020).

O monitoramento remoto e o gerenciamento de informações de saúde para pessoas fora do ambiente clínico e hospitalar têm sido favorecidos com o uso de aplicações para dispositivos móveis (SAPONARA et al., 2016). A ampla utilização de dispositivos eletrônicos portáteis em todo o mundo favorece sua aplicação formal nos serviços de saúde, subsidiando a conduta e a atuação dos profissionais de saúde (KÄLLANDER et al., 2013). De acordo com MOREIRA et al. (2020), o uso de aplicativos móveis para auxiliar na análise postural tem se mostrado confiável, podendo contribuir para a prática clínica dos profissionais de saúde, principalmente nas fases de avaliação e reavaliação dos tratamentos, apesar de apresentar algumas variações comparado a métodos tradicionais.

Nós últimos anos, com o surgimento de *big data* e o aumento substancial nas capacidades de computação paralela, *deep learning* (TONG et al., 2021; ZHANG et al., 2021) fez avanços nos campos de visão computacional (ZHANG et al., 2021; ZHANG et al., 2020) e processamento de linguagem natural (LU et al., 2021); especialmente nos objetivos, muitos avanços práticos foram feitos em detecção, tradução automática (YING et al., 2021) e reconhecimento de movimento. A detecção de alvos é um importante tópico de pesquisa da visão computacional. É a base de muitas tarefas de visão computacional (ZHANG et al., 2021). Também é amplamente utilizada na vida real. Por exemplo, algoritmos de detecção de alvo tradicionais, como reconhecimento facial (NING et al.; SUN et al., 2020). Outro importante tópico de pesquisa em visão computacional é a análise semântica de vídeo, particularmente o reconhecimento da ação humana, que possui uma ampla gama de cenários de aplicação, incluindo interação humano-computador e reconhecimento de gestos (LIJIN, 2021).

O reconhecimento de gestos do corpo humano é uma relevante direção de pesquisa da visão computacional (JIANG et al.; DE SMEDT et al., 2019). Seu objetivo final é produzir os parâmetros estruturais dos membros totais ou parciais da pessoa, como o contorno do corpo humano, a posição e orientação da cabeça e a posição dos pontos articulares humanos ou a categoria das partes. Deve-se dizer que os métodos de pesquisa de reconhecimento de gestos cobrem quase todas as teorias e tecnologias no campo da visão computacional, tais como reconhecimento de padrões, *machine learning*, inteligência artificial, gráficos de imagens e estatísticas (WANG et al., 2020; LIU et al., 2019).

2. Objetivos

Nesse contexto, busca-se investigar o potencial de aplicações móveis como ferramentas de auxílio no processo de avaliação física, e a possibilidade de contribuir para identificar desvios posturais como escoliose ou limitações articulares e musculares. Com o grande avanço tecnológico dos últimos anos, agora temos *smartphones* com cada vez mais poder computacional, o que acaba viabilizando inúmeras possibilidades de inovação, dentre elas, soluções que visem a saúde e bem-estar humano.

O presente artigo tem por objetivo final ou geral explorar a aplicação da visão computacional na análise da postura e ADM humanos, através das tecnologias embarcadas em dispositivos móveis. Sobre os objetivos específicos ou intermediários, tem-se: o desenvolvimento de um protótipo funcional de aplicativo para *iOS* cujas principais funcionalidades sejam a análise da postura e ADM humanos, contemplando desde aspectos de implementação até a análise dos dados obtidos pelo uso do aplicativo,

observando características como: capacidade, necessidades, limitações e obstáculos enfrentados.

Ao observar a lacuna existente na exploração acadêmica da visão computacional em aplicações móveis fazendo uso de tecnologias embarcadas como câmeras, sensores e processadores direcionados a tarefas de inteligência artificial, notou-se a viabilidade de elaborar um projeto de pesquisa com ênfase na disseminação do conhecimento sobre o processo de desenvolvimento dessas soluções e seu potencial de inspiração para novas soluções em diversas áreas da sociedade, neste especificamente, a saúde e bem-estar.

Além dessas lacunas que geram a oportunidade do projeto, existe a motivação pessoal dos autores, entusiastas de tecnologia e apaixonados por desenvolvimento de aplicações para dispositivos móveis.

3. Referencial Teórico

3.1. Desvios Posturais

A coluna vertebral humana está adaptada à posição ereta e é caracterizada pela presença de curvaturas fisiológicas denominadas cifose torácica (de 20º a 40º) (FON et al., 1980), lordose cervical (de 10º a 30º) (BATISTA JUNIOR et al., 2011) e lombar lordose (de 34º a 42º) (HARRISON et al., 1997) que ajudam a manter uma postura estável (BEEN et al., 2017; MROZKOWIAK et al., 2018). Quando o corpo humano é afetado por sobrecargas internas e externas, ocorrem mudanças no alinhamento da coluna (FEDORAK et al., 2003). A acentuação das curvaturas ântero-posterior e lateral, como hiperlordose (SHIRAZI et al., 2018), hipercifose (KATZMAN et al., 2010) (ambas maiores que 40º) e escoliose (maior que 10º) (REAMY et al., 2001; NAGHMAN et al., 2016), são ilustradas na Figura 1.

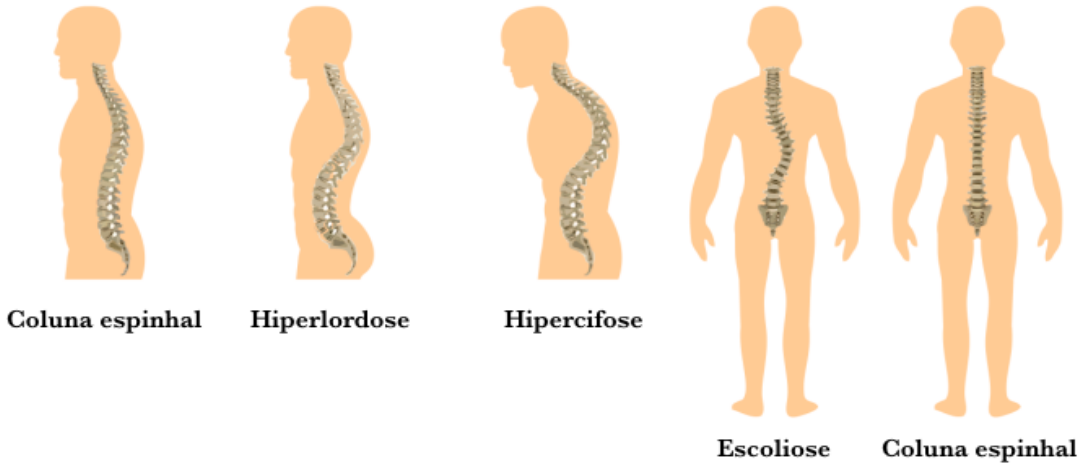


Figura 1. Desvios posturais

Fonte: ResearchGate

Aumentar ou diminuir essas curvaturas pode alterar a biomecânica corporal e, consequentemente, causar alterações na postura corporal e vice-versa. Além dos desalinhamentos causados por mudanças anatômicas na coluna, as pessoas adotam

posturas diárias de inclinar a cabeça, o tronco para frente, para trás ou para os lados. Isso por si só não é um problema, visto que as pessoas são seres assimétricos, mas, a longo prazo, essas inclinações situacionais também podem causar alterações biomecânicas e, portanto, também devem ser consideradas durante a avaliação postural (MAGEE e MANSKE, 2020).

3.2. Amplitude de movimento da coluna cervical

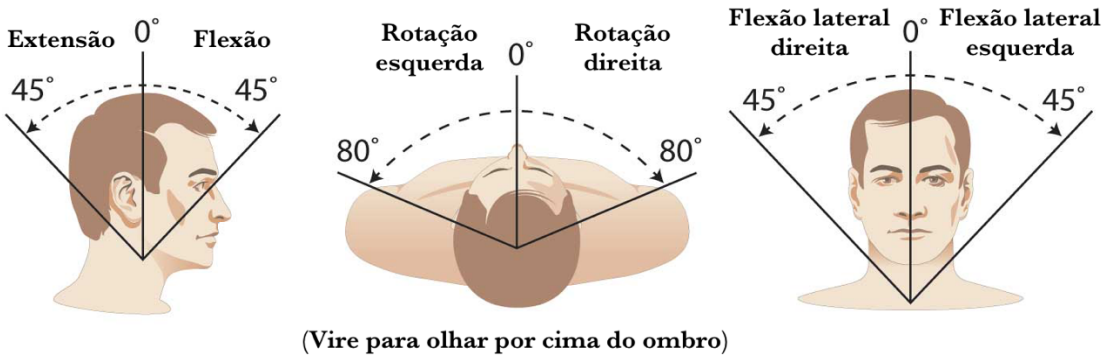


Figura 2. Amplitude de movimento da coluna cervical

Fonte: JEMS

A coluna cervical está envolvida com o processo de sustentação e movimentação da cabeça, proteção das estruturas neurais e vasculares. A coluna cervical realiza os movimentos de: flexão; extensão; flexão lateral direita e esquerda; e rotação direita e esquerda.

A flexão, é o movimento, no plano sagital, em que o mento se aproxima da parede anterior do tórax. A extensão, é o movimento, no plano sagital, em que a nuca se aproxima do dorso. A flexão lateral, é o movimento, no plano frontal em que a cabeça e o pescoço se aproximam do ombro direito ou esquerdo. A rotação, é o movimento no qual o pescoço e a cabeça giram para direita ou para esquerda em torno de um eixo vertical (JEMS, 2015).

3.3. Métodos para avaliar desvios de postura humana

Um dos métodos mais amplamente usados para avaliar os desvios da postura humana é a inspeção visual e palpação (TUNNELL, 1996). Esse método é altamente subjetivo e dependente do avaliador (WATSON e DONNCHA, 2000; RADAŠ e TROŠT BOBIC, 2011) e possui baixa confiabilidade e reprodutibilidade, o que torna sua aplicação no meio científico não recomendável (SINGLA e VEQAR, 2014). Para minimizar os vieses produzidos por esta análise, novos métodos de avaliação postural foram desenvolvidos (SEDREZ, 2016), os quais são baseados em ferramentas para auxiliar na avaliação manual, ferramentas digitais, métodos de radiografia (COBB, 1948; BONANNI, 2017) e soluções baseadas em computador.

3.4. Reconhecimento de gestos de movimento humano

De acordo com o Dicionário Oxford, a postura do corpo humano é uma postura especial do corpo e a forma como uma pessoa mantém seu estado físico (REN et al., 2020). O reconhecimento da postura humana e a descrição da linguagem natural. É um tema de

pesquisa que tem recebido grande atenção nos últimos anos. É uma pesquisa sobre a aplicação da fisiologia humana, processamento digital de imagens, reconhecimento de padrões e outras disciplinas do campo (LEE et al., 2020).

Da perspectiva da coleta de informações sobre a postura humana, a tecnologia de reconhecimento da postura humana pode ser dividida em duas categorias: tecnologia de reconhecimento de contato e tecnologia de reconhecimento sem contato (KHANIAN et al., 2020; ZHOU et al., 2019).

A tecnologia de reconhecimento de contato se refere ao corpo de uma pessoa usando um sensor, por meio do qual o sensor coleta informações de parâmetros, para realizar a análise e o reconhecimento da postura. Essa tecnologia pode capturar com precisão as mudanças na postura, permitindo que os usuários usem equipamentos de coleta de dados, e a taxa de reconhecimento de postura após a análise do computador é bastante alta. No entanto, em aplicações práticas, causará transtornos aos usuários e não atenderá aos requisitos de interação humano-computador. Ao mesmo tempo, esse equipamento é caro e difícil de ser popularizado.

A tecnologia de reconhecimento sem contato é geralmente baseada no reconhecimento de gestos humanos baseado na visão, ou seja, extraindo e reconhecendo características humanas por meio de vigilância por vídeo, que é um tema notável na visão computacional. Ela adquire informações de imagem por meio de dispositivos de captura de vídeo, como câmeras e, após o processamento e análise do computador, recursos representativos específicos são extraídos e classificados para obter o reconhecimento da postura.

3.5. Câmera com sensor de profundidade

Em geral, os métodos de aquisição de mapas de profundidade são divididos em duas categorias: ativo e passivo. A característica mais óbvia do método ativo é que o próprio equipamento precisa transmitir energia para completar a coleta de informações de profundidade. Isso garante que a imagem em profundidade seja obtida independentemente da imagem colorida. Nos últimos anos, os métodos ativos de aquisição de mapas de profundidade incluem principalmente *TOF* (*Time of Flight*) (ISSAQ et al., 2002), luz estruturada e *Kinect* (NGUYEN et al., 2020; TOLGYESSY et al., 2021), *LiDAR* (*Light Detection and Ranging*) (CHEN et al., 2017; MAO et al., 2020) e assim por diante.

O princípio da câmera *TOF* (ISSAQ et al., 2002) para obter uma imagem de profundidade é o seguinte: ao transmitir pulsos infravermelhos próximos e contínuos para a cena alvo, os pulsos de luz refletidos de volta do objeto são recebidos pelo sensor. Ao comparar a diferença de fase entre o pulso de luz emitido e o pulso de luz refletido pelo objeto, o atraso de transmissão entre o pulso de luz pode ser calculado e a distância do objeto em relação ao emissor pode ser obtida, resultando em uma imagem de profundidade. Ela tem um sensor infravermelho maior, um campo de visão mais amplo e um mapa de profundidade de maior qualidade. No entanto, a resolução da imagem em profundidade é muito menor do que a resolução da imagem colorida. O valor da profundidade é perturbado por ruído significativo, especialmente nas bordas do objeto. Além disso, as câmeras *TOF* geralmente são caras.

O princípio de aquisição de imagem em profundidade com base em luz estruturada (NGUYEN et al., 2020) é que a luz estruturada é projetada na cena, e o padrão

correspondente com luz estruturada é capturado pelo sensor de imagem. Uma vez que o padrão de luz estruturada mudará devido à forma do objeto, as informações de profundidade de cada ponto na cena podem ser obtidas calculando a posição da imagem padrão na imagem capturada e o grau de deformação usando o princípio de triangulação. Este método pode obter as informações tridimensionais do alvo com alta precisão e velocidade. No entanto, como o método de luz estruturada é facilmente afetado pela forte luz natural ao ar livre, ele não pode ser usado em tal ambiente. Além disso, ocorrerá perda de profundidade quando o objeto for preto ou a superfície do objeto for lisa. O *Kinect* (TOLGYESSY et al., 2021) adota uma tecnologia chamada *Light Coding*. Diferente da luz estruturada tradicional, o transmissor infravermelho codificado por luz do *Kinect* emite um "código estéreo" com profundidade tridimensional. Esse método também pode obter as informações tridimensionais do alvo com alta precisão e velocidade, mas o alcance efetivo é pequeno, o valor de profundidade está ausente e a borda da imagem de profundidade não corresponde à borda da imagem colorida e tem algum ruído.

O princípio de aquisição de informações de profundidade do *LiDAR* (CHEN et al., 2017; MAO et al., 2020) é que o *laser* é disparado para o espaço em um determinado intervalo de tempo, e o sinal de cada ponto de varredura é gravado do *LiDAR* para os objetos na cena medida, bem como o intervalo de tempo entre o sinal refletido ao *LiDAR* após o objeto, de modo a calcular a distância entre a superfície do objeto e o *LiDAR*. Por causa de sua ampla faixa e alta precisão de medição, o *LiDAR* é amplamente utilizado em sistemas de Inteligência artificial de percepção de espaço tridimensional ao ar livre, como navegação para evitar obstáculos de veículos autônomos, reconstrução de cena tridimensional e outras aplicações. No entanto, seu preço é relativamente alto e faltam informações sobre a textura do alvo.

Os métodos de aquisição de profundidade passiva incluem principalmente correspondência estéreo binocular ou multiocular (MA et al., 2020; ROGISTER et al., 2012) e estimativa de profundidade monocular (MING et al., 2021). O método de correspondência estéreo binocular ou multiocular usa várias câmeras separadas por uma certa distância para obter várias imagens da mesma cena ao mesmo tempo. Um algoritmo de correspondência estéreo é usado para encontrar os pixels correspondentes em várias imagens e, em seguida, a informação de disparidade é calculada de acordo com o princípio da triangulação. As informações de disparidade podem ser transformadas para representar as informações de profundidade dos objetos na cena. Este método tem baixos requisitos de *hardware* e pode ser aplicado a cenas internas e externas. No entanto, ele tem alta complexidade computacional para realizar a correspondência estéreo *pixel* a *pixel* e é difícil fazer a correspondência em cenas com falta de textura e em cenas com mudanças severas de iluminação. Além disso, este método requer uma calibração complexa da câmera.

Segundo a APPLE INC (2021), a funcionalidade de reconhecimento facial presente em alguns modelos de *iPhone* produzidos pela empresa a partir de 2017, é ativada por uma das mais avançadas tecnologias de *hardware* e *software* que eles já desenvolveram. A câmera *TrueDepth* captura dados do rosto com precisão analisando e projetando milhares de pontos invisíveis para criar um mapa de profundidade do rosto, além de capturar uma imagem infravermelha dele. Uma parte do *Neural Engine* (unidade de processamento neural), dos *chips A11*, *A12 Bionic*, *A12X Bionic*, *A13 Bionic*, *A14 Bionic* e *A15 Bionic*, protegida pelo *Secure Enclave*, transforma o mapa de profundidade e a imagem

infravermelha em uma representação matemática e a compara com os dados faciais registrados.

O *Face ID*, nome dado a tal funcionalidade, adapta-se automaticamente às mudanças no visual, como o uso de maquiagem ou barba crescida. Se houver uma mudança mais significativa na aparência, como tirar a barba, o *Face ID* confirmará a identidade usando o código de acesso antes de atualizar os dados do rosto. O *Face ID* foi desenvolvido para funcionar com chapéus, lenços, óculos, lentes de contato e diferentes tipos de óculos de sol. Além disso, ele funciona em ambientes externos e internos e até mesmo no escuro.

3.6. *Neural Engine*

Um acelerador de inteligência artificial é uma classe de acelerador de hardware especializado (V3, 2017) ou sistema de computador (INSIDE HPC, 2017; VENTURE BEAT, 2019) projetado para acelerar aplicativos de inteligência artificial e *machine learning*, incluindo redes neurais artificiais e visão computacional. As aplicações típicas incluem algoritmos para robótica, internet das coisas e outras tarefas intensivas de dados ou acionadas por sensores (EE TIMES, 2016). Frequentemente, são *designs* de muitos núcleos e geralmente se concentram em aritmética de baixa precisão, novas arquiteturas de fluxo de dados ou capacidade de computação *in-memory*. Em 2018, um chip de circuito integrado de inteligência artificial típico continha bilhões de transistores MOSFET (COMPUTER HISTORY MUSEUM, 2018). Existem vários termos específicos do fornecedor para dispositivos nesta categoria, e é uma tecnologia emergente sem um design dominante.

Os *chips A11*, *A12 Bionic*, *A12X Bionic*, *A13 Bionic*, *A14 Bionic* e *A15 Bionic*, presentes em alguns dos modelos mais recentes do *iPhone*, possuem *hardware* de rede neural dedicado que a *Apple* chamada de "*Neural Engine*". Esse *hardware* de rede neural pode realizar até 600 bilhões de operações por segundo no *chip A11* e é usado para *Face ID*, *Animoji* e outras tarefas de *machine learning* (APPLE INC, 2017). O *Neural Engine* permite que a *Apple* implemente a rede neural e o *machine learning* de uma maneira mais eficiente em termos de energia do que usando a *CPU (Central Process Unit)* principal ou a *GPU (Graphics Processing Unit)* (EXTREMETECH, 2017; BLOOMBERG, 2017).

3.7. Sistema Operacional

Um sistema operacional é um software de sistema que gerencia o hardware do computador, recursos de software e fornece serviços comuns para programas de computador (GAGNE, 2012).

No ecossistema da *Apple*, existe uma variedade de sistemas operacionais desenvolvidos para cada tipo de dispositivo produzido pela empresa. Sendo os mais relevantes para esse projeto, o *macOS* e o *iOS*. O *macOS* em conjunto com o *Xcode*, ambiente de desenvolvimento integrado da *Apple*, são as principais ferramentas para desenvolvimento de aplicações para o seu ecossistema. Já o *iOS*, é o sistema operacional móvel do *iPhone* (APPLE INC, 2021), *smartphone* cuja algumas das tecnologias embarcadas serão exploradas nesse projeto.

3.8. *Frameworks*

Na programação de computador, um *framework* é uma abstração na qual o *software*, fornecendo funcionalidade genérica, pode ser alterado seletivamente por código adicional

escrito pelo usuário, fornecendo assim *software* específico para o aplicativo. Ele fornece uma maneira padrão de construir e implantar aplicativos e é um ambiente de *software* universal e reutilizável que fornece funcionalidade específica como parte de uma plataforma de *software* maior para facilitar o desenvolvimento de aplicativos de *software*, produtos e soluções. As estruturas de *software* podem incluir programas de suporte, compiladores, bibliotecas de código, conjuntos de ferramentas e *application programming interfaces (APIs)* que reúnem todos os diferentes componentes para permitir o desenvolvimento de um projeto ou sistema (RIEHLE, 2000).

A *Apple Inc*. mantém *frameworks* disponíveis à comunidade de desenvolvedores de aplicativos para suas plataformas, dentre elas, o *iOS*. Esses frameworks são integráveis a aplicações desenvolvidas nas linguagens de programação Swift e Objective-C. Um deles é *framework* de visão computacional, chamado *Vision*. O *Vision*, aplica algoritmos de visão computacional para realizar uma variedade de tarefas na entrada de imagens e vídeo. Ele realiza detecção de rosto e pontos de referência, detecção de texto, reconhecimento de código de barras, registro de imagem e rastreamento de recursos gerais. O *Vision* também permite o uso de modelos personalizados do *Core ML*, outro *framework* mantido pela *Apple*, para tarefas como classificação ou detecção de objetos.

O *Core ML*, por outro lado é usado para integrar modelos de *machine learning* nos aplicativos. Os aplicativos através das *APIs* do *Core ML* e dados do usuário, conseguem fazer previsões e treinar ou ajustar modelos, tudo no dispositivo do usuário.



Figura 3. Core ML

Fonte: Apple Inc.

Como representado na Figura 3, um modelo é o resultado da aplicação de um algoritmo de *machine learning* a um conjunto de dados de treinamento. Um modelo é utilizado para fazer previsões com base em novos dados de entrada. Os modelos podem realizar uma ampla variedade de tarefas que seriam difíceis ou impraticáveis de escrever em código. Por exemplo, treinar um modelo para categorizar fotos ou detectar objetos específicos em uma foto diretamente de seus *pixels*. A construção e treinamento de modelos podem ser feitos usando o aplicativo *Create ML*, incluso no *Xcode*, usado para o desenvolvimento de software para suas plataformas. Sendo possível também, a integração com uma variedade de outras bibliotecas de *machine learning*.

O *Core ML* otimiza o desempenho do dispositivo, aproveitando a *CPU*, *GPU* e o *Neural Engine* enquanto minimiza sua pegada de memória e consumo de energia. Executar um modelo estritamente no dispositivo do usuário remove qualquer necessidade de uma conexão de rede, o que ajuda a manter os dados do usuário privados e a aplicação responsiva. Ele é a base para *frameworks* e funcionalidades específicas de domínio.

Oferecendo suporte para outros *frameworks* como *Vision* na análise de imagens, *Natural Language* para processamento de texto, *Speech* para conversão de áudio em texto e *Sound Analysis* para identificação de sons e áudio. E se baseia em primitivos de baixo nível como *Accelerate* e *BNNS*, bem como *Metal Performance Shaders* (APPLE INC, 2021).

4. Metodologia

O projeto teve início com uma pesquisa na literatura para compreender as limitações, práticas e métodos tradicionais de análise da postura humana, bem como o uso de soluções de software para dispositivos móveis a fim de auxiliar e otimizar o processo de avaliação física. Após a pesquisa preliminar, foi então, verificada a carência de uma outra pesquisa em referência à aplicação da visão computacional através das tecnologias embarcadas nesses dispositivos. A partir disso, foi realizada a escolha e validação de tecnologias para a elaboração de um protótipo.

4.1. Escolha e validação de tecnologias

Foi feita a escolha do iOS, como plataforma para a execução do protótipo a ser desenvolvido, pois possibilitaria uma validação futura com uma grande gama de usuários, como também pelas tecnologias embarcadas em seus dispositivos, como o *Neural Engine* e a câmera *TrueDepth*. Sendo utilizada a versão 15 do iOS, pois inclui algumas funcionalidades novas de interesse do estudo, como a adição da captura do movimento da coluna cervical no eixo X.

A critério dos autores, foi utilizado um *iPhone 11 Pro*, como principal dispositivo no processo de desenvolvimento e validação do aplicativo. Esse dispositivo possui um processador *A13 Bionic*; *Neural Engine* de terceira geração; e câmera frontal de 12 *MP* e abertura de *ƒ*/2,2. Utilizamos também um *MacBook Pro 16-inch, 2019*, com processador 2,6 *GHz 6* núcleos *Intel Core i7*, memória de *16 GB 2667 MHz DDR4*, placa gráfica *AMD Radeon Pro 5300M 4 GB* e *macOS Monterey*, versão 12.0.

Como ambiente de desenvolvimento integrado, fizemos uso do Xcode em sua versão 13.0, que contempla o suporte para a versão 15 do iOS. A linguagem de programação Swift, versão 5.5, foi adotada para o desenvolvimento do projeto, sendo ela de domínio dos autores e de fácil entendimento, quando comparada com a outra opção, a linguagem de programação Objective-C. Foram utilizados os *frameworks Vision* e *Core ML*, sendo o primeiro para pré-processamento das imagens e o segundo para a inferência dos pontos-chave do corpo humano.

4.2. Elaboração do protótipo

Enfim, teve início o desenvolvimento de um protótipo funcional de aplicativo, para iOS, voltado a análise e monitoramento da postura e ADM humanos. Desenvolveu-se esse protótipo utilizando o Xcode, a linguagem de programação Swift e os frameworks, Vision e Core ML, da Apple.

As funcionalidades do aplicativo foram divididas em duas: a análise e monitoramento da ADM da coluna cervical observando a cabeça e a análise da postura corporal. Foi seguida a *pipeline* de inferência representada na Figura 4.

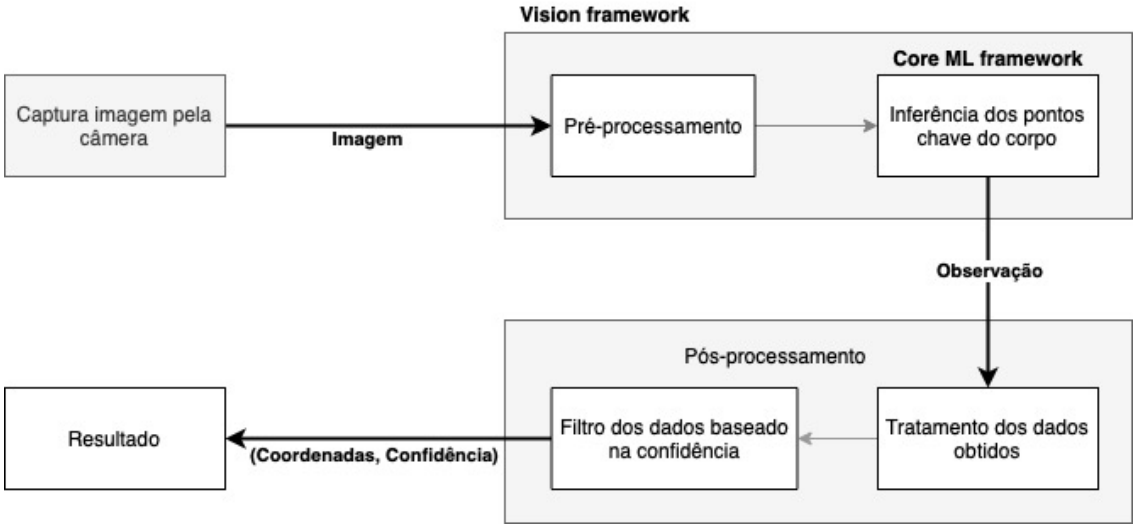


Figura 4. Pipeline de inferência

Fonte: autores

Na análise da postura da coluna cervical observando a cabeça, seguindo os fundamentos de aerodinâmica, as informações de interesse extraídas das observações fornecidas, são as medidas angulares representadas por *roll*, *pitch* e *yaw*, acompanhadas de suas respectivas confidências. Sendo o *roll* o movimento de rotação no eixo Z, o *pitch* o movimento de rotação no eixo X e o *yaw* o movimento de rotação no eixo Y.

Na análise da postura corporal, as informações de interesse extraídas das observações fornecidas, são as coordenadas para 19 pontos articulares do corpo humano, sendo eles: tornozelo direito; tornozelo esquerdo; joelho direito; joelho esquerdo; quadril direito; quadril esquerdo; base; pulso direito; pulso esquerdo; cotovelo direito; cotovelo esquerdo; ombro direito; ombro esquerdo; pescoço; orelha direita; orelha esquerda; olho direito; olho esquerdo e nariz. Sendo também a variação angular entre esses pontos de grande importância para se fazer uma análise postural e avaliar a ADM do corpo.

4.3. Validação do protótipo

Buscou-se avaliar aspectos de implementação até a análise dos dados obtidos pelo uso do aplicativo desenvolvido, observando características como: capacidade, necessidades, limitações e obstáculos enfrentados. Para isso, observamos dados como tempo de inferência, confidência das observações e *FPS (Frames Per Second)* ao executar o aplicativo.

5. Resultados

5.1. Análise da ADM da coluna cervical

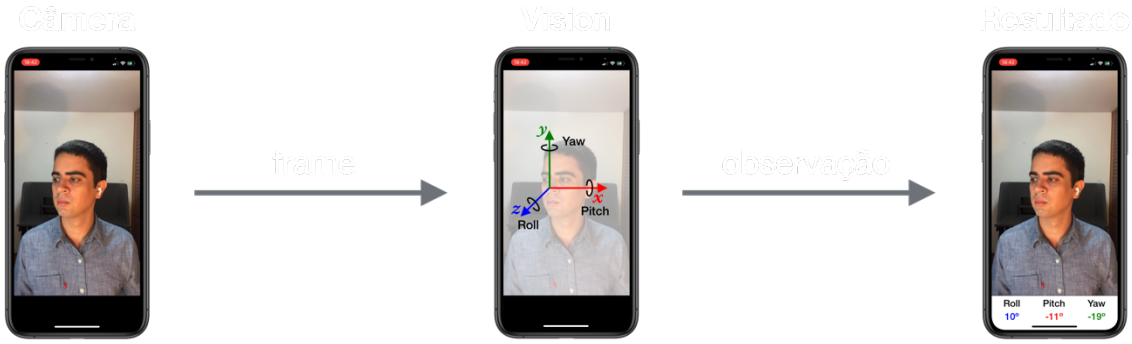


Figura 5. Workflow da análise da ADM da coluna cervical

Fonte: autores

Apresentado na Figura 5, o *workflow* de inferência da análise da ADM da coluna cervical, consiste em capturar o *buffer* da câmera do dispositivo, frame a frame solicitar para que o *Vision* em conjunto com o *Core ML* analise a imagem e retorne uma observação contendo as informações de interesse e por fim essas informações são filtradas pela confidência, transformadas de radianos para graus e exibidas na interface do aplicativo.

Nessa análise, conseguimos observar a ADM da coluna cervical, tendo como referência a cabeça. Em repouso, as medidas ideais para *roll*, *pitch* e *yaw* devem se aproximar de 0º. Ao movimentar a cabeça, conseguimos observar a amplitude do movimento em cada eixo, ao obter suas medidas angulares. O *roll*, varia ao efetuar o movimento de flexão lateral; o *pitch*, varia ao efetuar o movimento de flexão; e o *yaw*, varia ao efetuar o movimento de rotação.

No processo de avaliação da funcionalidade, foram notadas algumas necessidades que valem a pena serem mencionadas, como o posicionamento e estabilização da câmera do dispositivo; boa iluminação e contraste no campo de visão da câmera para otimizar a precisão da análise. Ao respeitar os requisitos, a confidência do modelo se manteve acima dos 80% de acurácia e não houve queda significativa no *FPS*, mantendo-se constante em 60 *FPS*.

5.2. Análise da postura frontal do corpo

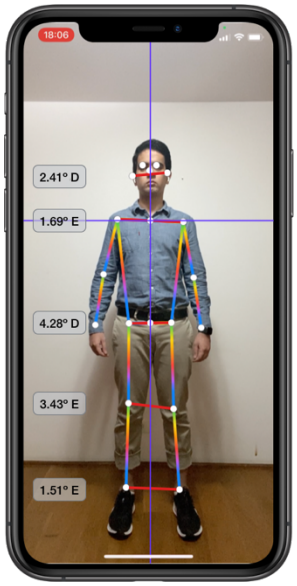


Figura 6. Análise da postura frontal do corpo

Fonte: autores

Seguindo um workflow de inferência similar, a análise da postura frontal do corpo, conforme apresentado na Figura 6, são identificados os 19 pontos de articulação do corpo, mencionados anteriormente, sendo os pontos importantes para essa análise, ligados por um seguimento de reta vermelho. Então, são calculados os ângulos de inclinação, tendo os eixos horizontal e vertical como referências. Como podemos observar, a cabeça está levemente inclinada a direita (D) em 2.41º, o ombro está levemente inclinado a esquerda (E) em 1.69º e assim por diante. Essas medidas variam de acordo com a movimentação do corpo e as medidas ideais em repouso seriam medidas que se aproximam de 0º.

Sendo a distância entre o usuário e a câmera um fator determinante para a precisão no posicionamento dos pontos referentes as orelhas, os olhos e nariz. O nivelamento da câmera também tende a influenciar nos resultados. Ao respeitar os requisitos, a confidência do modelo se manteve acima dos 70% de acurácia e não houve queda significativa no *FPS*, mantendo-se constante em 30 *FPS*.

5.3. Análise da postura lateral do corpo



Figura 7. Análise da postura lateral do corpo

Fonte: autores

Na análise da postura lateral do corpo, conforme apresentada na Figura 7, foi feito um filtro nos pontos de articulação do corpo observados, para serem exibidos apenas os pontos de interesse. Sendo eles: orelha esquerda; ombro esquerdo; quadril esquerdo; joelho esquerdo; e tornozelo esquerdo. Esse filtro foi realizado para que se tivesse uma imagem menos poluída e de fácil entendimento. Os pontos de interesse são ligados por um seguimento de reta, vermelho, perpendicular ao eixo vertical. Então, são calculados os ângulos de inclinação, tendo o eixo vertical como referência. Como podemos observar, a cabeça está inclinada para frente (F) em 6.74º, o ombro está levemente inclinado para F em 0.58º, e assim por diante. Sendo que quando há inclinação para trás, ela é representada pela letra T. Essas medidas também variam de acordo com a movimentação do corpo e as medidas ideais em repouso seriam medidas que se aproximam de 0º.

O posicionamento do usuário frente à câmera é um fator determinante para a precisão no posicionamento dos pontos de interesse e análise. O nivelamento da câmera também tende a influenciar nos resultados. Ao respeitar os requisitos, a confidência do modelo se manteve acima dos 70% de acurácia e não houve queda significativa no *FPS*, mantendo-se constante em 30 *FPS*.

6. Conclusões

Esse projeto teve como propósito investigar o potencial de aplicações móveis como ferramentas de auxílio no processo de avaliação física, e a possibilidade de contribuir para identificar desvios posturais como escoliose ou limitações articulares e musculares. Com o grande avanço tecnológico dos últimos anos, agora temos *smartphones* com cada vez mais poder computacional, o que acaba viabilizando inúmeras possibilidades de inovação, dentre elas, soluções que visem a saúde e bem-estar humano.

A visão computacional e tecnologias embarcadas em dispositivos móveis, apesar de ainda possuírem algumas limitações, estão cada vez mais acessíveis e com capacidade

melhorada, o que no entendimento dos autores e corroborado pela literatura, possibilita a criação de soluções promissoras no auxílio da análise postural e de ADM humanos.

Através do aplicativo conseguimos analisar a postura e ADM da coluna cervical, tendo a cabeça como referência, em tempo real e com confidência acima de 80%. Além de analisar a postura frontal e lateral do corpo, com confidência acima de 70%. Ambos os modelos foram utilizados pelo *Vision* através do *Core ML*.

Porém, foram notadas algumas necessidades, como posicionar e estabilizar a câmera do dispositivo, ter boa iluminação e contraste no campo de captura da câmera para otimizar a precisão da análise. A padronização dos métodos de medida angular é recomendada para que haja uniformidade entre os estudos quanto à altura da câmera, distância usuário-câmera, dispositivo utilizado, e acurácia do modelo usado para geração dos dados normativos dos ângulos posturais.

7. Trabalhos Futuros

As tecnologias embarcadas em dispositivos móveis estão em constante evolução. Em virtude disso, o aplicativo desenvolvido pode ainda ser aprimorado e incrementado com mais funcionalidades como, a análise da ADM de outras partes do corpo e aprimoramento do modelo para identificação de desvios posturais específicos, como a escoliose.

Também ficou clara a necessidade de validação com especialistas da área da saúde, e avaliação e proposta de uma padronização dos métodos de medida angular para que haja uniformidade entre os dados coletados quanto à altura da câmera, distância usuário-câmera, dispositivo utilizado, e acurácia do modelo usado para geração dos dados normativos dos ângulos posturais.

Referências

APPLE INC, Sobre a tecnologia avançada do Face ID, [S. l.], 2021. Disponível em: https://support.apple.com/pt-br/HT208108. Acesso em: 14 nov. 2021.

APPLE INC, The future is here: iPhone X (Press release), [S. l.], 2017. Disponível em: https://www.apple.com/newsroom/2017/09/the-future-is-here-iphone-x/. Acesso em: 14 nov. 2021.

BATISTA JUNIOR, J.L.; BATISTA, P.R.d.; BARBOSA, D.M.; MACHADO, I.C.; REZENDE, R. Evaluation of cervical behavior in patients with scoliosis Lenke who underwent surgery. Coluna Columna 2011, 10, 231–233.

BEEN, E.; GÓMEZ-OLIVENCIA, A.; SHEFI, S.; SOUDACK, M.; BASTIR, M.; BARASH, A. Evolution of Spinopelvic Alignment in Hominins. Anat. Rec. 2017, 300, 900–911.

BLOOMBERG, Apple Is Working on a Dedicated Chip to Power AI on Devices, [S. l.], 2017. Disponível em: https://www.bloomberg.com/news/articles/2017-05-26/apple-said-to-plan-dedicated-chip-to-power-ai-on-devices. Acesso em: 14 nov. 2021.

BONANNI, P.G. Contour and Angle-Function Based Scoliosis Monitoring: Relaxing the Requirement on Image Quality in the Measurement of Spinal Curvature. Int. J. Spine Surg. 2017, 11.

CDC, Computer Vision Development for Estimating Trunk Angles, [S. l.], 2020. Disponível em: https://blogs.cdc.gov/niosh-science-blog/2020/12/09/computer-vision/. Acesso em: 14 nov. 2021.

CHEN, L.; HE, Y.; CHEN, J.; LI, Q.; ZOU, Q. "Transforming a 3-D LiDAR point cloud into a 2-D dense depth map through a parameter self-adaptive framework," IEEE Transactions on Intelligent Transportation Systems, vol. 18, no. 1, pp. 165–176, 2017.

CHEN, G. Q.; MAO, Z. Z.; YI, H. L.; et al. "Pedestrian detection based on panoramic depth map transformed from 3d-lidar data," Periodica Polytechnica Electrical Engineering and Computer Science, vol. 64, no. 3, pp. 274–285, 2020.

COBB, J.R. Outline for the study of scoliosis. Instr. Course Lect. 1948, 5, 261–275.

COMPUTER HISTORY MUSEUM, 13 Sextillion & Counting: The Long & Winding Road to the Most Frequently Manufactured Human Artifact in History, [S. l.], 2018. Disponível em: https://computerhistory.org/blog/13-sextillion-counting-the-long-winding-road-to-the-most-frequently-manufactured-human-artifact-in-history/?key=13-sextillion-counting-the-long-winding-road-to-the-most-frequently-manufactured-human-artifact-in-history. Acesso em: 14 nov. 2021.

EE TIMES, Google Designing AI Processors, [S. l.], 2016. Disponível em: https://www.eetimes.com/google-designing-ai-processors/. Acesso em: 14 nov. 2021.

EXTREMETECH, What to Expect from Apple's Neural Engine in the A11 Bionic SoC, [S. l.], 2017. Disponível em: https://www.extremetech.com/mobile/255780-apple-neural-engine-a11-bionic-soc. Acesso em: 14 nov. 2021.

FEDORAK, C.; ASHWORTH, N.L.; MARSHALL, J.C.; PAULL, H. Reliability of the visual assessment of cervical and lumbar lordosis: How good are we? Spine 2003, 28 16, 1857–1859.

FON, G.T.; PITT, M.J.; THIES, A.C. Thoracic kyphosis: Range in normal subjects. Am. J. Roentgenol. 1980, 134 5, 979–983.

GAGNE, S. G. Operating Systems Concepts. New York: Wiley, 2012. ISBN: 978-1118063330.

HARRISON, D.; JANIK, T.; TROYANOVICH, S.; COLLOCA, C. Evaluation of the assumptions used to derive an ideal normal cervical spine model. J. Manip. Physiol. Ther. 1997, 20, 246–256.

INSIDE HPC, Inspurs unveils GX4 AI Accelerator, [S. l.], 2017. Disponível em: https://insidehpc.com/2017/06/inspurs-unveils-gx4-ai-accelerator/. Acesso em: 14 nov. 2021.

ISSAQ, H. J.; VEENSTRA, T. D.; CONRADS, T. P.; FELSCHOW, D. "The seldi-tof ms approach to proteomics: protein profiling and biomarker identification," Biochemical and Biophysical Research Communications, vol. 292, no. 3, pp. 587–592, 2002.

JEMS, Why EMS Should Limit the Use of Rigid Cervical Collars, [S. l.], 2015. Disponível em: https://www.jems.com/patient-care/why-ems-should-limit-use-rigid-cervical/. Acesso em: 14 nov. 2021.

KÄLLANDER, K.; TIBENDERANA, J.K.; AKPOGHENETA, O.J.; STRACHAN, D.L.; HILL, Z.; ASBROEK, A.H.A.; CONTEH, L.; KIRKWOOD, B.R.; MEEK, S.R.

Mobile Health (mHealth) Approaches and Lessons for Increased Performance and Retention of Community Health Workers in Low- and Middle-Income Countries: A Review. J. Med. Internet Res. 2013, 15, e17.

KATZMAN, W.B.; WANEK, L.; SHEPHERD, J.A.; SELLMEYER, D.E. Age-Related Hyperkyphosis: Its Causes, Consequences, and Management. J. Orthop. Sport. Phys. Ther. 2010, 40, 352–360.

LIJIN, Z., "Computer Vision-Driven Evaluation System for Assisted Decision-Making in Sports Training", Wireless Communications and Mobile Computing, vol. 2021, Article ID 1865538, 7 pages, 2021. DOI: 10.1155/2021/1865538.

LU, Y.; LI, W.; NING, X.; et al. "Blind image quality assessment based on the multiscale and dual-domains features fusion," Concurrency and Computation: Practice and Experience, no. article e6177, 2021.

MA, W.-P.; LI, W.-X.; CAO, P.-X. "Binocular vision object positioning method for robots based on coarse-fine stereo matching," International Journal of Automation and Computing, vol. 17, no. 4, pp. 562–571, 2020.

MAGEE, D. J.; MANSKE, R. C. Orthopedic Physical Assessment, 7th edition. Philadelphia: Saunders, 2020. ISBN: 9780323522991.

MING, Y.; MENG, X.; FAN, C.; YU, H. "Deep learning for monocular depth estimation: a review," Neurocomputing, vol. 438, pp. 14–33, 2021.

MOREIRA, R. et al. Mobile Applications for Assessing Human Posture: A Systematic Literature Review. Electronics, v. 9, n. 8, p. 1196, 25 jul. 2020.

MROZKOWIAK, M.; WALICKA-CUPRYS, K.; MAGON, G. Comparison of Spinal Curvatures in the Sagittal Plane, as Well as Body Height and Mass in Polish Children and Adolescents Examined in the Late 1950s and in the Early 2000s. Med. Sci. Monit. 2018, 24, 4489–4500.

NAGHMAN, C.M.; ZAFAR, A.; RAJAT, V. Adolescent Idiopathic Scoliosis. Open Orthop. J. 2016, 10, 143–154.

NGUYEN, H.; WANG, Y. Z.; WANG, Z. Y. "Single-shot 3d shape reconstruction using structured light and deep convolutional neural networks," Sensors (Switzerland), vol. 20, no. 13, pp. 1–13, 2020.

NING, X.; DUAN, P.; LI, W.; ZHANG, S. "Real-time 3D face alignment using an encoder-decoder network with an efficient deconvolution layer," IEEE Signal Processing Letters, vol. 27, pp. 1944–1948, 2020.

RADAŠ, J.; TROŠT BOBIC, T. Posture in top-level Croatian rhythmic gym nasts and non-trainees. Kinesiology 2011, 43, 64–73.

REAMY, B.; SLAKEY, J. Adolescent idiopathic scoliosis: Review and current concepts. Am. Fam. Physician 2001, 64, 111–116.

RIEHLE, D. *Framework Design: A Role Modeling Approach.* Ph.D. Thesis, No. 13509. Zürich, Switzerland, ETH Zürich, 2000.

ROGISTER, P.; BENOSMAN, R.; IENG, S. H.; LICHTSTEINER, P.; DELBRUCK, T. "Asynchronous event-based binocular stereo matching," IEEE Transactions on Neural Networks and Learning Systems, vol. 23, no. 2, pp. 347–353, 2012.

SAPONARA, S.; DONATI, M.; FANUCCI, L.; CELLI, A. An Embedded Sensing and Communication Platform, and a Healthcare Model for Remote Monitoring of Chronic Diseases. Electronics 2016, 5, 47.

SEDREZ, J.; CANDOTTI, C.; FURLANETTO, T.; LOSS, J. Non-invasive postural assessment of the spine in the sagittal plane: A systematic review. Motricidade 2016, 12, 140.

SHIZAZI, S.A.; HAGHIGHI, F.M.; ALAVI, S.M.; NEZHAD, F.F.; EMAMI, F. Is application of Kinesio tape to treat hyperlordosis more effective on abdominal muscles or hamstrings? J. Res. Med. Sci. 2018, 23, 9.

SINGLA, D.; VEQAR, Z. Methods of Postural Assessment Used for Sports Persons. J. Clin. Diagn. Res. 2014, 8, LE01–LE04.

SUN, L.; LI, W.; NING, X.; ZHANG, L.; DONG, X.; HE, W. "Gradient-enhanced softmax for face recognition," IEICE Transactions on Information and Systems, vol. E103.D, no. 5, pp. 1185–1189, 2020.

TOLGYESSY, M.; DEKAN, M.; CHOVANEC, L.; HUBINSKY, P. "Evaluation of the azure Kinect and its comparison to Kinect V1 and Kinect V2," Sensors, vol. 21, no. 2, pp. 1–25, 2021.

TONG, Y.; YU, L.; LI, S.; LIU J.; QIN, H.; LI, W. "Polynomial fitting algorithm based on neural network," ASP Transactions on Pattern Recognition and Intelligent Systems, vol. 1, no. 1, pp. 32–39, 2021.

TUNNELL, P.W. Protocol for visual assessment: Postural evaluation of the muscular system through visual inspection. J. Bodyw. Mov. Ther. 1996, 1, 21–27.

VENTURE BEAT, Neural Magic raises $15 million to boost AI inferencing speed on off-the-shelf processors, [S. l.], 2019. Disponível em: https://web.archive.org/web/20200306120524/https://venturebeat.com/2019/11/06/neural-magic-raises-15-million-to-boost-ai-training-speed-on-off-the-shelf-processors/. Acesso em: 14 nov. 2021.

V3, Intel unveils Movidius Compute Stick USB AI Accelerator, [S. l.], 2017. Disponível em: https://web.archive.org/web/20170811193632/https://www.v3.co.uk/v3-uk/news/3014293/intel-unveils-movidius-compute-stick-usb-ai-accelerator. Acesso em: 14 nov. 2021.

WATSON, A.W.; DONNCHA, C.M. A reliable technique for the assessment of posture: Assessment criteria for aspect of posture. J. Sport. Med. Phys. Fit. 2000, 40 3, 260–270.

WONG, W. Y., WONG, M. S. and LO, K. H. (2007) 'Clinical Applications of Sensors for Human Posture and Movement Analysis: A Review', *Prosthetics and Orthotics International*, 31(1), pp. 62–75. DOI: 10.1080/03093640600983949.

YING, C.; SHUYU, Y.; JING, L.; LIN, D.; QI, Q. "Errors of machine translation of terminology in the patent text from English into Chinese," ASP Transactions on Computers, vol. 1, no. 1, pp. 12–17, 2021.

ZHANG, J.; LIU, Y.; LIU, H.; WANG, J. "Learning local–global multiple correlation filters for robust visual tracking with Kalman filter redetection," Sensors, vol. 21, no. 4, p. 1129, 2021.

ZHANG, J.; SUN, J.; WANG, J.; YUE, X. G. “Visual object tracking based on residual network and cascaded correlation filters,” Journal of Ambient Intelligence and Humanized Computing, vol. 12, 2021.

ZHANG, J.; JIN, X.; SUN, J.; WANG, J.; SANGAIAH, A. K. “Spatial and semantic convolutional features for robust visual object tracking,” Multimedia Tools and Applications, vol. 79, no. 21-22, pp. 15095–15115, 2020.